ESTUDO DE CASO: CLASSIFICAÇÃO DE AVALIAÇÕES DE PRODUTOS

1 - CONTEXTUALIZAÇÃO

Uma empresa de comércio eletrônico deseja desenvolver um sistema capaz de identificar automaticamente se as avaliações realizadas por seus clientes sobre determinado produto possuem caráter positivo ou negativo.

Para isso, a empresa disponibilizou o arquivo Excel “avaliacoes.xlsx”, contendo 100 avaliações de clientes sobre um determinado produto. Cada avaliação possui aproximadamente 200 caracteres e apresenta diferentes formas de escrita, podendo conter palavras semelhantes, variações de termos e diferentes construções de frases.

O objetivo desta atividade é desenvolver um programa em Python capaz de utilizar técnicas de similaridade textual para classificar automaticamente as avaliações.

2 – ARQUIVO FORNECIDO

O arquivo “avaliacoes.xlsx” contém 100 avaliações e duas colunas:

Coluna	Descrição
ID	Identificador numérico da avaliação.
avaliacao	Texto da avaliação realizada pelo cliente.

3. AVALIAÇÕES DE REFERÊNCIA

Para realizar a classificação, serão utilizadas duas avaliações de referência: uma positiva e uma negativa.

Referência positiva

“O produto possui excelente qualidade, chegou rapidamente e atendeu completamente às minhas expectativas. Gostei muito da compra e recomendo este produto para outras pessoas.”

Referência negativa

“O produto possui péssima qualidade, apresentou problemas logo após a compra e não atendeu às minhas expectativas. Fiquei muito decepcionado e não recomendo este produto.”

4. OBJETIVO DA ATIVIDADE

Desenvolver um programa em Python que leia as avaliações do arquivo Excel e determine, para cada uma delas, se o texto apresenta maior proximidade com a avaliação positiva ou com a avaliação negativa, utilizando as métricas de Jaccard e Levenshtein.

5. DESENVOLVIMENTO DA ATIVIDADE

5.1 Leitura do arquivo Excel

O programa deverá realizar a leitura do arquivo “avaliacoes.xlsx” e percorrer as 100 avaliações. Recomenda-se a utilização da biblioteca pandas para manipulação dos dados.

5.2 Pré-processamento dos textos

Antes do cálculo das métricas, os textos deverão passar por uma etapa de pré-processamento. No mínimo, deverão ser realizadas as seguintes operações:

- Conversão dos textos para letras minúsculas;
- Remoção de pontuação;
- Remoção de espaços desnecessários;
- Tokenização das palavras.

5.3 Similaridade de Jaccard

Para cada avaliação, deverá ser calculada a similaridade de Jaccard em relação às duas avaliações de referência.

$$J(A,B) = |A \cap B| / |A \cup B|$$

Na atividade, A e B representam os conjuntos de palavras dos dois textos comparados. A interseção representa as palavras presentes nos dois textos, enquanto a união representa todas as palavras presentes nos textos.

5.4 Distância de Levenshtein

Também deverá ser calculada a distância de Levenshtein entre cada avaliação e as duas avaliações de referência. A distância de Levenshtein representa a quantidade mínima de operações necessárias para transformar uma sequência de caracteres em outra. As operações consideradas são:

- Inserção de um caractere;
- Remoção de um caractere;
- Substituição de um caractere.

Para cada avaliação deverão ser obtidos a distância em relação à referência positiva e a distância em relação à referência negativa. Como se trata de uma distância, valores menores indicam maior proximidade entre os textos.

6. CLASSIFICAÇÃO DAS AVALIAÇÕES

A classificação deverá ser realizada separadamente para cada métrica.

Métrica	Condição	Classificação
Jaccard	Jaccard Positivo > Jaccard Negativo	POSITIVA
Jaccard	Jaccard Positivo ≤ Jaccard Negativo	NEGATIVA
Levenshtein	Levenshtein Positivo < Levenshtein Negativo	POSITIVA
Levenshtein	Levenshtein Positivo ≥ Levenshtein Negativo	NEGATIVA

7. TABELA DE RESULTADOS

O programa deverá apresentar os resultados de forma organizada. A tabela final deverá conter, no mínimo, as seguintes informações:

ID	Avaliação	Jaccard Pos.	Jaccard Neg.	Class. Jaccard	Lev. Pos.	Lev. Neg.	Class. Lev.
1	Texto da avaliação...	0,42	0,18	Positiva	125	183	Positiva

9. ANÁLISE DOS RESULTADOS

Após executar o programa, responda às seguintes questões:

1. Quantas avaliações foram classificadas como positivas pela métrica de Jaccard?

2. Quantas avaliações foram classificadas como negativas pela métrica de Jaccard?

3. Quantas avaliações foram classificadas como positivas pela distância de Levenshtein?

4. Quantas avaliações foram classificadas como negativas pela distância de Levenshtein?

5. Em quantas avaliações as duas métricas produziram a mesma classificação?

6. Em quantas avaliações as métricas produziram classificações diferentes?

7. Por que Jaccard e Levenshtein podem produzir resultados diferentes para uma mesma avaliação?

8. Qual das duas métricas apresentou maior sensibilidade às diferenças entre os textos? Justifique sua resposta com base nos resultados obtidos.

10. ENTREGA

A entrega deverá conter:

- Código-fonte em Python (.py);
- Arquivo Excel contendo os resultados da classificação;
- Breve relatório contendo
- Gravar um vídeo explicando sobre o que foi desenvolvido. O vídeo deve conter: a metodologia utilizada, explicação dos principais trechos de código, os resultados obtidos, a comparação entre Jaccard e Levenshtein, a análise das divergências e a conclusão.